

2017-2018-1 CS28010 类脑智能期中考试

隋国新

2017 年 11 月 26 日

1 (视觉理论) 请用自己的语言解释

(a) Wiesel-Hubel 特征检测理论

(b) Marr 的视觉计算理论

There are

2 (回归分析) 感知机 perceptron

(a) 用自己的语言结合公式解释什么是 perceptron

(b) 请解释为什么用 perceptron 没有办法解决 XOR (异或) 的求解

(c) 如何变化 perceptron 使之解决问题 b)?

(a) MP 神经元模型中, 神经元接收到来自 n 个其他神经元传递过来的输入信号, 这些输入信号通过带权重的连接进行传递, 神经元接收到的总输入值将与神经元的阈值比较, 通过激活函数处理产生神经元的输出。

perceptron 由两层神经元组成, 输入层接收外界输入信号后传递给输出层, 输出层是一个 MP 神经元。

(b) XOR 是一个非线性可分问题。perceptron 只有一层功能神经元, 而 MP 神经元本质上是对输入进行线性处理后通过一个单调的激活函数, 故不能解决这样的问题。

(c) 可以使用多层功能神经元。

3 (最小平方拟合) 数据集 $x_i, i = 1, \dots, n$, 其中 x_i 是一个 d 维向量。假设它们的均值为 0。现有一个单位长向量 w 。 x_i 沿着向量 a_i 在 w 上的投影为 \hat{x}_i

(a) 请写出 \hat{x}_i 关于 x_i, a_i 和 w 的表达式

(b) 求出使 $\sum_{i=1}^n \|\hat{x} - x_i\|$ 最小的 a_i 和 w

4 (高斯分布) $G(x|\mu_x, \sigma^2 I) = \frac{1}{(2\pi)^{d/2} \sigma^d} \exp(-\frac{1}{2\sigma^2}(x - \mu_x)^T(x - \mu_x))$, 其中 x 为 d 维向量。 $G(y|\mu_y, \Sigma) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp(-\frac{1}{2}(x - \mu_y)^T \Sigma^{-1}(x - \mu_y))$, 其中 y 为 d 维向量。 X 和 y 之间满足 $x = By$

- (a) 请写出 B 的表达式
- (b) 请针对 B 表达式的形式来解释 B 的含义 (对 y 做了什么操作得到 x)

(a) 根据题意我们有:

$$\begin{aligned} E(x) &= E(By) \\ &= BE(y) \\ Cov(x) &= Cov(By) \\ &= E[(By - E(By))(By - E(By))^T] \\ &= E(Byy^T B^T - BE(y)y^T B^T - ByE(y)^T B^T + BE(y)E(y)^T B^T) \\ &= E(Byy^T B^T - B\mu_y\mu_y^T B^T) \\ &= B(E(yy^T) - \mu_y\mu_y^T)B^T \\ &= B\Sigma B^T \end{aligned}$$

$$\text{即: } \begin{cases} \mu_x = B\mu_y \\ \sigma^2 I = B\Sigma B^T \end{cases}$$

- (b) 由 $\mu_x = B\mu_y$ 可知将 y 的均值移动至 x 的均值处, 由 $\sigma^2 I = B\Sigma B^T$ 可知将 y 的方差压缩, 对角线方向调整至 σ , 反对角线方向分布密度与对角线方向一致。

5 (统计决策) 请用自己的语言结合公式解释

- (a) Bayesian classification
- (b) Fisher discriminant analysis
- (c) 它们的区别

(a) 根据贝叶斯定理, $P(c|x) = \frac{P(c)P(x|c)}{P(x)}$, 其中 $P(c)$ 是分类为 c 的先验概率, $P(x|c)$ 是给定类标记后样本 x 的条件概率。Bayesian classification 就是根据这个公式, 基于训练数据估计 $P(c)$ 和 $P(x|c)$, 进而求出后验概率 $P(c|x)$ 。

- (b) Fisher discriminant analysis
- (c) 它们的区别

6 (高斯因子分析) 请用自己的语言结合公式解释 linear Gaussian factor analysis($X = Ay + e$) 的

- (a) scale 不确定性
- (b) rotation 不确定性
- (c) additive 不确定性
- (d) dimension 不确定性
- (e) 若 factor y 的分布从高斯分布变成二项分布, 上述不确定性还存在么? 为什么?

定义 A 是一个 $n \times m$ 的矩阵, n 是 x 的维数, m 是 y 的维数, $m < n$

- (a) scale 不确定性: y 服从于一个 m 维的高斯分布, 均值与方差的 scale 都不确定, 并且可以随着 A 的 scale 做出相应调整, 存在 scale 不确定性
- (b) rotation 不确定性: 若不对 y 做特殊限制, y 可以旋转, 存在 rotation 不确定性
- (c) additive 不确定性: 考虑 Ay 与 e 的值的分配, 二者的尺度都不确定时, additive 不确定性存在
- (d) dimension 不确定性: y 的维度 m 不确定, 存在 dimension 不确定性
- (e) 若 factor y 的分布从高斯分布变成二项分布, scale 不确定性, rotation 不确定性, dimension 不确定性消失, 只有 additive 不确定性。

7 (最小平方聚类)

- (a) 用自己的语言结合公式解释什么是最小平方聚类
 - (b) 最小平方聚类有三个无法解决的问题, 它们分别是什么? 为什么会存在?
 - (c) 就 k-means 算法而言, 在计算条件允许的情况下, 给定类别数 k , 如何求最优聚类?
 - (d) 但是因为代价太高, 一般会使用近似算法来求局部最优解。请用 EM 的思路来解释这个近似求解算法。(需要公式推导过程)
-
- (a) 给定样本集 $x_i, i = 1, \dots, m$, 聚类后获得簇划分 $C_i, i = 1, \dots, k$, 最小平方聚类方法最小化平方误差 $E = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|_2^2$, E 值越小簇内样本相似度越高。
 - (b)
 - 必须事先给出 K , 而且对初值敏感, 对于不同的初始值, 结果可能不同
 - 只能发现球状 Cluster, 不适合于发现非凸形状的簇或者大小差别很大的簇
 - 对噪声和孤立点数据敏感, 如簇中含有异常点, 将导致均值偏离严重。
 - (c) 每一个数据点的分类有 k 种, 所有点的分类有 k^m 种, 计算所有情况的平方误差, 取最优解
 - (d) 假定样本以各自的簇为中心满足高斯分布, 则可以使用 EM 混合高斯模型。根据 EM 算法,
 - 选择初始的 K 个类别中心 $\mu_i, i = 1, \dots, k$
 - M-step: $\theta := \operatorname{argmax} \sum_i \sum_{c^i} \log \frac{p(x_i, c_i; \theta)}{Q_i(c^i)}$
将软分类退化为硬分类, 则有 $c_i := \operatorname{argmax}(p(x_i, c_i; \theta))$
不考虑高斯分布方差, 则有 $c_i := \operatorname{argmin} \|x_i - \mu_i\|^2$
即对于每个样本 x_i , 将其标记为距离类别中心最近的类别

- E-step: $Q_i(c^i) = p(c_i|x_i, \theta)$
将软分类退化为硬分类后，不考虑概率，更新簇中心为 $\mu_j := \frac{\sum_{i=1}^m 1_{c_i=j} x_i}{\sum_{i=1}^m 1_{c_i=j}}$
- 重复前两步，直到类别中心的变化小于某阈值或者达到最大迭代次数